PostGreSQL sans schéma avec Python

Martin Kirchgessner / CTO Luxia / @martin_kirch

Meetup Python Grenoble - 27 Nov. 2019

 Il était une fois…

Un blog

```python
from uuid import uuid4
from sqlalchemy import Column, String, TIMESTAMP
from sqlalchemy.dialects.postgresql import UUID
from sa_metadata import Base

class Article(Base):
    __tablename__ = 'articles'

    uuid = Column(UUID(as_uuid=True), primary_key=True, default=uuid4)
    date = Column(TIMESTAMP(timezone=True), nullable=False)
    title = Column(String, nullable=False)
    content = Column(String, nullable=False)
```

On peut écrire

```
article = Article(
    date=datetime.now(),
    title="Super Python Blog #1",
    content="Hello World")

session.add(article)
session.commit()
```

Et rechercher

```
articles = (session.query(Article)
                   .order_by(Article.date.desc())
                   .limit(5)
                   .all()
)
log.info("Latest 5 articles in blog:")

for article in articles:
    log.info("%r", article)
```

« et si on ajoutait »

- L’auteur
- Des auteurs
- Un slug
- Plusieurs slugs
- Des tags
- Une miniature
- …

🧞 JSONB 🎉

- Un type de colonne
- ⚠️ JSON != JSONB ⚠️
- Syntaxe un peu lourde en SQL

  Par exemple `ma_colonne->'level' = '1'::jsonb`

  mais merci `jsonb_pretty(ma_colonne_jsonb)` !

La classe

```
from sqlalchemy.ext.mutable import MutableDict
from sqlalchemy.dialects.postgresql import JSONB

class Article(Base):
    __tablename__ = 'articles_with_extra'

    uuid = Column(UUID(as_uuid=True), primary_key=True, default=uuid4)
    date = Column(TIMESTAMP(timezone=True), nullable=False)
    title = Column(String, nullable=False)
    content = Column(String, nullable=False)
    extra = Column(MutableDict.as_mutable(JSONB), nullable=False, default={})
```

Enregistrons un slug

```
article = Article(
    date=datetime.now(),
    title="Super Python Blog #3",
    content="Hello World of URI slugs",
    extra={
        'slug': 'super-python-blog-3'
    })
```

```
article = (session
    .query(Article)
    .filter(Article.extra['slug'].astext == 'super-python-blog-3')
    .first()
)
```

Enregistrons des tags

```
article = Article(
    date=datetime.now(),
    title="Super Python Blog #4",
    content="Now with tags",
    extra={
        'tags': ["JSONB", "PostGreSQL", "Python"]
    })


by_tag = (session
    .query(Article)
    .filter(Article.extra.contains(
        {'tags': ["PostGreSQL"]}
    ))
   .all()
)
```

⚠️ Mise à jour dangereuse

```
article = (session
    .query(Article)
    .filter(Article.extra.contains(
        {'tags': ["PostGreSQL"]}))
    .first()
)
article_uuid = article.uuid
article.extra['tags'][0] = "JSON"
session.commit()

# ... plus tard, dans un session lointaine

article = session.query(Article).get(article_uuid)

# article.extra['tags'][0] ==??
```

🤓 Solution

```
article = (session
    .query(Article)
    .filter(Article.extra.contains(
        {'tags': ["PostGreSQL"]}))
    .first()
)
article.extra['tags'][0] = "JSON"
article.extra.changed() # 👀 👀 👀 👀 👀
session.commit()

# ... plus tard, dans un session lointaine

article = session.query(Article).get(article_uuid)

# article.extra['tags'][0] == "JSON" \o/
```

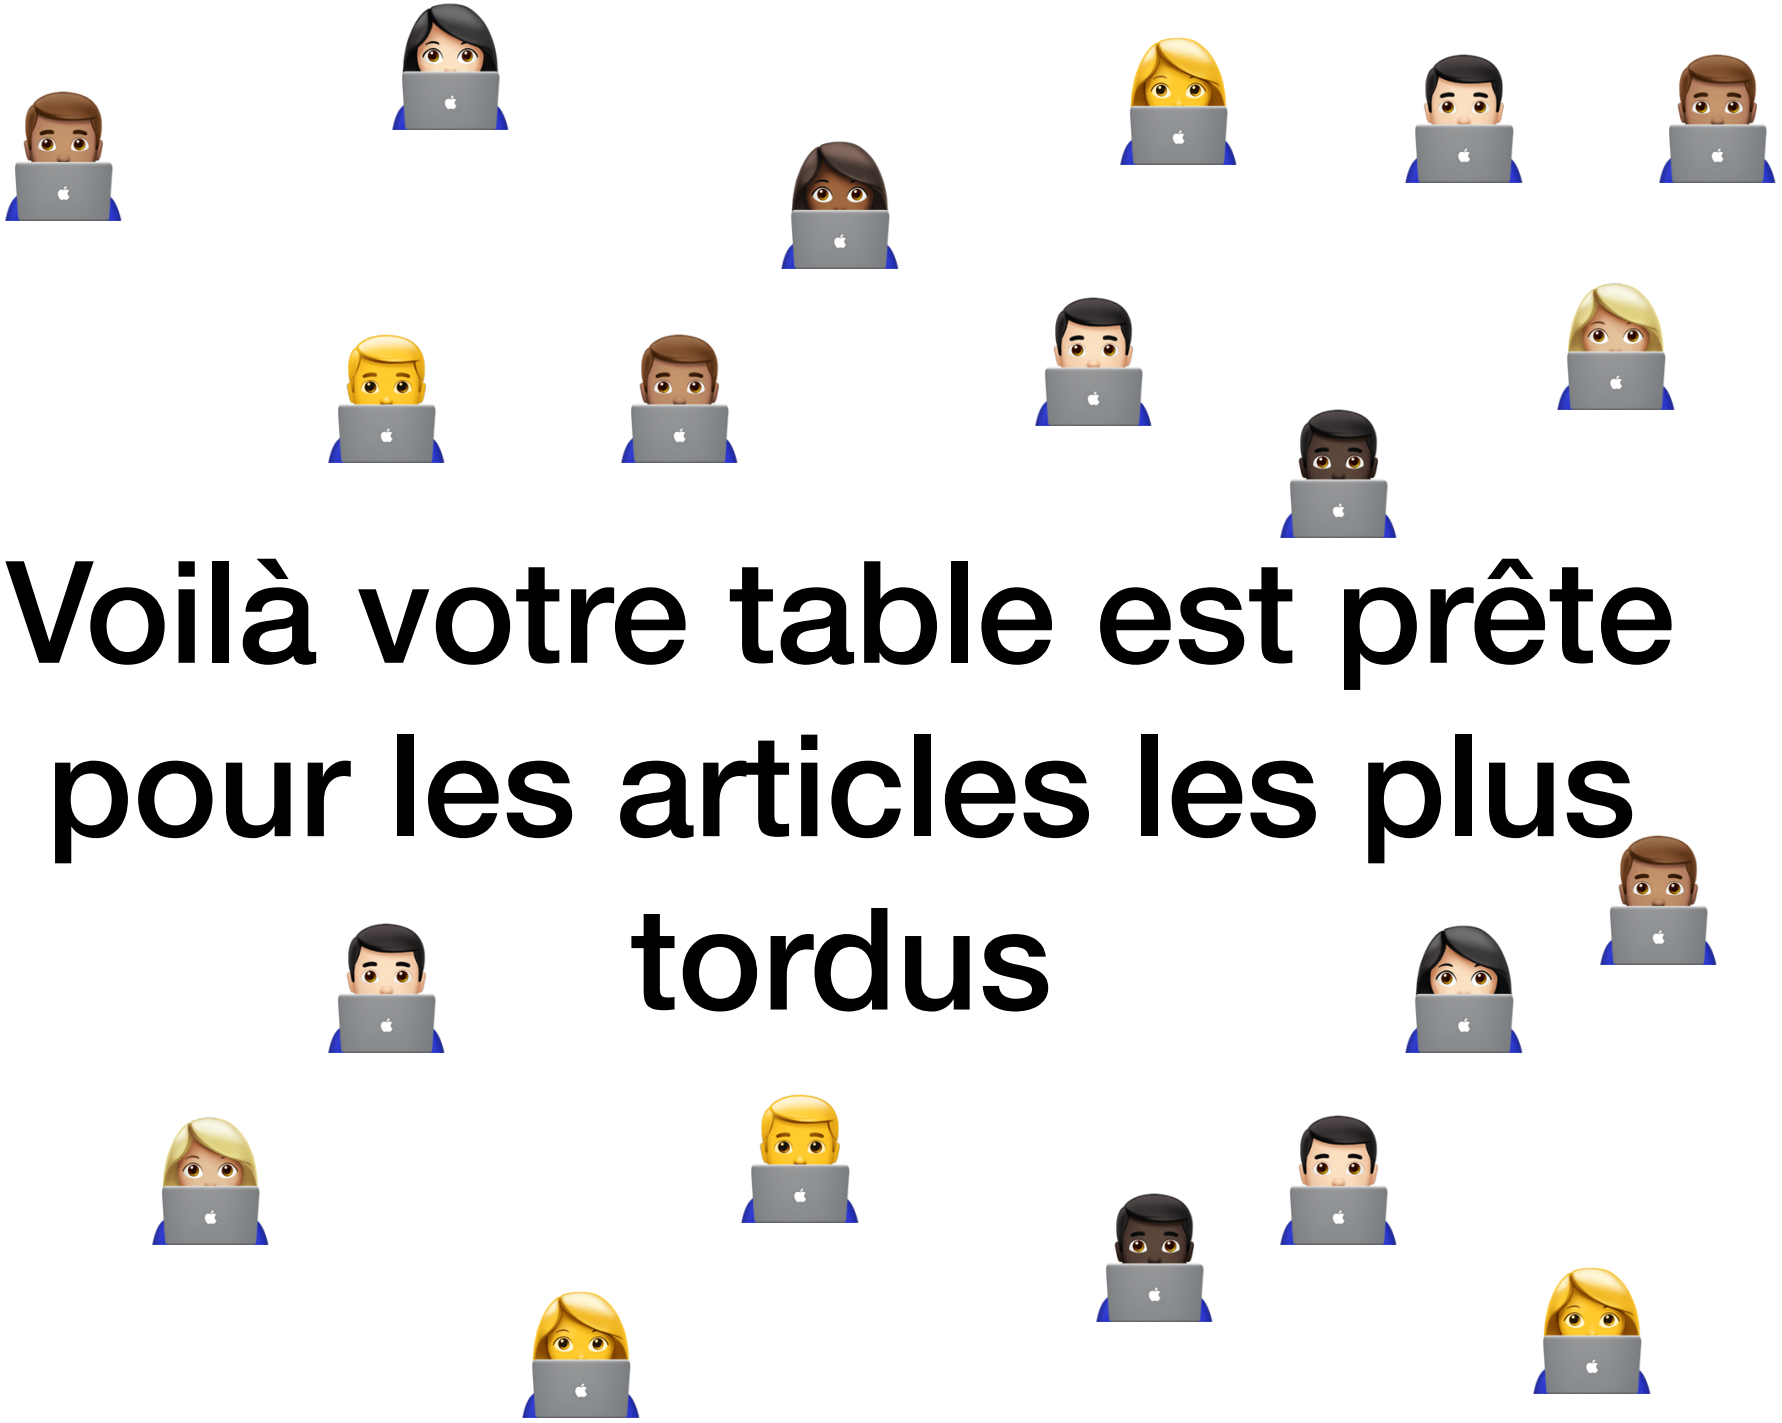
Voilà votre table est prête pour les articles les plus tordus

📚📚 Quand soudain 📚📚

- Déjà 1 million d’articles !
- La recherche est leeeente

Recherche par date

```
by_date = (session
    .query(Article)
    .filter(Article.date == datetime(2019, 11, 27))
    .all()
)
```

Recherche par date

```
date = Column(TIMESTAMP(timezone=True), nullable=False, index=True)
```

Recherche par slug

```
extra = Column(
    MutableDict.as_mutable(JSONB),
    nullable=False,
    default={}
)

__table_args__ = (
    Index(
        'ix_articles_polymorphic_extra_slug',
        extra['slug'].astext),
    )
)
```

Rechercher par tag

```
extra = Column(
    MutableDict.as_mutable(JSONB),
    nullable=False,
    default={}
)

__table_args__ = (
    Index(
        'ix_articles_polymorphic_extra_tag',
        extra['tags'],
        postgresql_using='gin'
    )
)
```

GIN=General Inverted Index

🐎 et ça repart 🏇

🤔 … mais c’est un schéma caché, non ?

😱 L’autre schéma caché

Le code devient envahi de tests comme

```
if ‘tags’ in extra
…
if isinstance(extra['tags'], list)
```

Le polymorphisme

SQLAlchemy va instancier une classe différente en fonction d'un critère donné

```
class Article(Base):
    # … pareil … plus une colonne :
    article_type = Column(Integer)

    __mapper_args__ = {
        'polymorphic_on': article_type,
        'polymorphic_identity': None,
    }
```

👩‍👧‍👧 Deux sous-classes

```
'polymorphic_on': article_type,
…
class TaggedArticle(Article):
    __mapper_args__ = {
        'polymorphic_identity':
            ArticleType.TAGGED.value}

class ImageArticle(Article):
    __mapper_args__ = {
        'polymorphic_identity':
            ArticleType.IMAGE.value}

class ArticleType(Enum):
    TAGGED = 1
    IMAGE = 2
```

Exemples 👀

```
tagged = TaggedArticle(
    date=datetime.now(),
    title="My first tagged article",
    content="Bla bla bla",
    extra={'tags': ['blog']},
)

image = ImageArticle(
    date=datetime.now(),
    title="My first picture",
    content="https://example.com/favicon.ico",
)
```

Exemples 👀

```
articles = (session
     .query(Article)
     .order_by(Article.date.desc())
     .limit(5)
     .all()
)
```

➡️ **Mélange de TaggedArticle et ImageArticle**

Exemples 👀

```
count = (session
    .query(TaggedArticle)
    .filter(Article.extra.contains(
        {'tags': ["article"]}
    )).count()
```

Magie de calendriers

- On peut fournir nos (dé)sérialiseurs JSON
  (lors de la création de la connexion)

- Mais, en SQL, '2019-11-27' < '2019-11-27 00:00:00’

```
filter(Article
   .extra[‘first_publication_date’]
   .astext.cast(Date) >= my_datetime)
```

Utilisation chez LUXIA

- Télécharge/traite/indexe des documents juridiques
- Tout ça dans une table Documents
- Bientôt 100 sous-classes de Document
- Avec de l’héritage multiple, des mixins
- Au fait : on recrute !

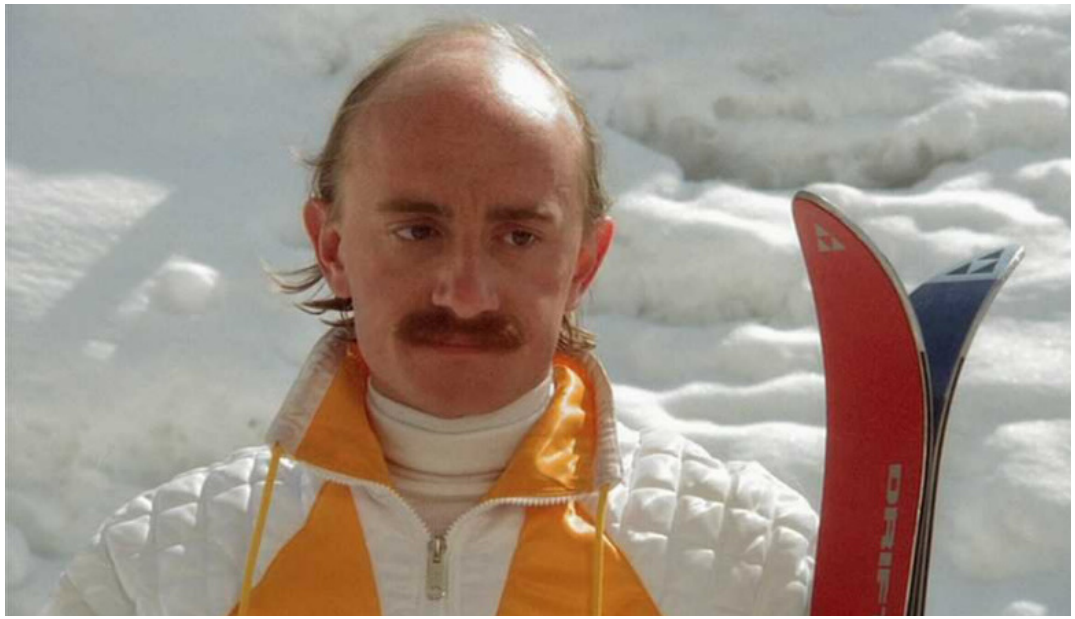

Pour conclure

 Pas trop de schema

- Mais un peu quand même
- Des colonnes JSON partout « au cas où »
- Compétitif avec Mongo/Couch/Elastic/…
  - Sauf si vous écrivez *beaucoup*

Existe en tableau

```
sa.Column(
    MutableList.as_mutable(
        postgresql.ARRAY(sa.BigInteger))
```

Alembic

- Versionne le schéma à partir des classes SQLAlchemy
- Mais pas les index /JSON

Tout cela est dans un projet-demo :

https://github.com/martinkirch/jsonb-sqlalchemy-demo

?